

## Задача оценивания угловых координат неподвижных объектов по наблюдениям с пропусками.

М. В. Лебедев<sup>\**a*</sup>, К. В. Семенихин<sup>\**b*</sup>, Г. Ф. Суржиков<sup>\**c*</sup>

*\*Московский авиационный институт (национальный исследовательский университет),  
Москва, Россия*

*e-mail: <sup>a</sup>max\_max82@inbox.ru, <sup>b</sup>siemenku@gmail.com, <sup>c</sup>gfsurzhikov@gmail.com*

Поступила в редакцию XX.XX.2026

**Аннотация**—В работе построен ЕМ-алгоритм для оценивания угловых координат неподвижных объектов при наличии пропусков в наблюдениях, полученных линейной равномерной антенной решеткой. Пропуски в наблюдениях рассматриваются как результат стохастических аппаратных сбоев. В качестве скрытых переменных рассматриваются как пропуски в наблюдениях, так и исходные сигналы. Предложенный алгоритм способен находить оптимальные оценки угловых координат при достаточно хорошей инициализации и малом числе источников сигналов.

**КЛЮЧЕВЫЕ СЛОВА:** оценивание угловых координат, ЕМ-алгоритм, наблюдения с пропусками, линейная равномерная антенна решетка, оценка максимального правдоподобия.

### 1. ВВЕДЕНИЕ

В парадигме статистической обработки сигналов особое место занимает задача оценивания угловых координат (DoA) источников сигналов [1, 2]. Существуют две основные категории методов для оценивания угловых координат: подпространственные (к примеру, CAPON, MUSIC, ESPRIT), основанные на разбиении ковариационной матрицы наблюдений на подпространство, соответствующее сигналу, и подпространство, соответствующее шуму, и методы, основанные на поиске ММП-оценки. Последние оказываются особенно полезными в постановках задач, предполагающих относительно низкое отношение сигнал-шум, корреляцию между сигналами или малое число наблюдений.

Одним из классических подходов к поиску оценки максимального правдоподобия в моделях с неполными наблюдениями является ЕМ-алгоритм [3]. В контексте задач оценивания угловых координат источников скрытые переменные позволяют переформулировать задачу таким образом, что применение ЕМ-алгоритма становится естественным и вычислительно удобным. В практических приложениях зачастую используются модификации этого алгоритма, позволяющие упростить оптимизацию на M-шаге (ЕСМ-алгоритм, [4]), либо обеспечивающие более быструю сходимость (SAGE-алгоритм, [5]), и подобные методы уже применяются для оценивания угловых координат источников [6–8]. Данные алгоритмы используют предположение об известной ковариационной матрице шума. Активное развитие получили методы, использующие ЕМ-алгоритм в условиях априорной неопределенности ковариационной матрицы шума [9–11]. В то время как в вышеприведенных работах используется пространственная обработка сигналов, в [12] предлагается подход на основе временной обработки сигналов с использованием ЕМ-алгоритма, в роли скрытых переменных рассматриваются систематические ошибки измерения разностей времени прихода сигнала (TDoA). В [13] построен ЕМ-алгоритм для оценивания угловых координат и иных характеристик сигналов для беспроводной сенсорной сети.

В реальных условиях эксплуатации сенсоры могут быть подвержены стохастическим аппаратным сбоям, вследствие чего их показания в определенные моменты времени могут не быть надежными. В [14] ЕМ-алгоритм используется для оценивания характеристик сигнала в беспроводной сенсорной сети, причем алгоритм также оценивает исправность узлов этой сети.

В работе формулируется задача поиска оптимальных оценок угловых координат неподвижных источников сигналов в условиях, когда часть сенсоров подвержены аппаратным сбоям или случайным помехам, и, ввиду этого, часть наблюдений содержит случайные по своему происхождению пропуски. Используется методология, основанная на представлении сигнала и шума в комплексной форме, сигнал и шум предполагаются дискретными независимыми комплексными гауссовскими процессами с независимыми одинаково распределенными отсчетами. В качестве скрытых переменных рассматриваются исходные сигналы и пропуски в наблюдениях. Ввиду чувствительности ЕМ-алгоритма к инициализации, используется мультистарт, для первой итерации используется оценка, полученная алгоритмом MUSIC, на последующих - случайные смещения указанной оценки. В условиях, когда число сенсоров оказывается меньше числа наблюдений, причем от трети и более сенсоров ненадежны, оценки, полученные с помощью алгоритма MUSIC оказываются существенно смещенными, в то же время предложенный в работе ЕМ-алгоритм позволяет получить оценки угловых координат, для которых характеристично значительно меньшее смещение относительно истинных значений параметров.

Структура статьи включает в себя: описание модели и формулировку задачи в разделе 2; представление ЕМ-алгоритма для оценивания угловых координат неподвижных источников сигналов в разделе 3; анализ результатов численного эксперимента в разделе 4; заключительные выводы в разделе 5.

## 2. ОПИСАНИЕ МОДЕЛИ И ПОСТАНОВКА ЗАДАЧИ

Предположим, имеется линейная равномерная антенная решетка, состоящая из  $L$  сенсоров, которая принимает узкополосные сигналы, направленные из  $K$  удаленных источников, причем  $K < L$ . Этим источникам соответствуют угловые координаты (DoA)  $\theta = [\theta_1, \dots, \theta_K]^T$ , практически не изменяющиеся во времени. По итогам измерений было получено  $T$  снимков полученного сигнала, причем ввиду стохастических технических сбоев, связанных с сенсорами, часть таких снимков содержит помимо доступных данных пропуски. Матрица принятых сигналов (наблюдений)  $X$  является результатом следующей модели наблюдений:

$$X = \mathbf{A}(\theta)S + N, \quad (1)$$

где

$$X = [X_1, \dots, X_T], S = [S_1, \dots, S_T], N = [N_1, \dots, N_T],$$

и  $X_t \in \mathbb{C}^L, S_t \in \mathbb{C}^K, N_t \in \mathbb{C}^L$  – векторы-столбцы, соответствующие наблюдениям, сигналам и шумам в момент времени  $t = 1, \dots, T$ ,  $\mathbf{A}(\theta)$  – матрица направляющих векторов для линейной равномерной антенной решетки размера  $L \times K$ :

$$\mathbf{A}(\theta) = \begin{bmatrix} 1 & 1 & \dots & 1 \\ e^{-2i\pi \frac{d}{\lambda} \sin(\theta_1)} & e^{-2i\pi \frac{d}{\lambda} \sin(\theta_2)} & \dots & e^{-2i\pi \frac{d}{\lambda} \sin(\theta_K)} \\ \dots & \dots & \ddots & \vdots \\ e^{-2i\pi(L-1)\frac{d}{\lambda} \sin(\theta_1)} & e^{-2i\pi(L-1)\frac{d}{\lambda} \sin(\theta_2)} & \dots & e^{-2i\pi(L-1)\frac{d}{\lambda} \sin(\theta_K)} \end{bmatrix},$$

где  $i$  – мнимая единица,  $d$  – расстояние между сенсорами,  $\lambda$  – длина волны,  $\theta_k$  – угловая координата  $k$ -го источника,  $k = 1, \dots, K$ . Через  $x = [x_1, \dots, x_T]$  будем обозначать реализацию случайной матрицы  $X = [X_1, \dots, X_T]$ . Для каждого момента времени  $t = 1, \dots, T$  определено

непустое множество индексов, соответствующих доступным (для наблюдения) компонентам вектора  $X_t$ :  $o_t \subseteq \{1, \dots, L\}$ ,  $1 \leq |o_t| \leq L$ , и множество индексов, соответствующих пропускам в векторе  $X_t$ :  $m_t \subset \{1, \dots, L\}$ , причем  $o_t \cup m_t = \{1, \dots, L\}$ ,  $o_t \cap m_t = \emptyset$ ,  $\forall t \in \{1, \dots, T\}$ . Доступная и недоступная части вектора  $X_t$  обозначаются через  $X_{t,o_t} = ((X_t)_i)_{i \in o_t} \in \mathbb{C}^{|o_t|}$  и  $X_{t,m_t} = ((X_t)_i)_{i \in m_t} \in \mathbb{C}^{|m_t|}$  соответственно. Таким образом, будем считать, что набор наблюдений  $X$  состоит из доступной части  $X_o = \{X_{t,o_t}\}_{t=1}^T$  и недоступной:  $X_m = \{X_{t,m_t}\}_{t=1}^T$ . Предполагается, что пропуски в наблюдениях  $X_t$  являются абсолютно случайными, то есть относятся к типу MCAR по классификации Дональда Рубина [15]. Вероятность возникновения таких пропусков не зависит от значений доступных для наблюдений или тех значений, что были пропущены. Также предполагается, что для реализации  $x$  случайной матрицы  $X$  расположение пропусков известно.

Сигналы, испускаемые источниками, шумы на сенсорах и наблюдения предполагаются стохастическими:  $S_t \sim \mathcal{CN}(\mathbf{O}_{K \times 1}, \boldsymbol{\Gamma})$ ,  $N_t \sim \mathcal{CN}(\mathbf{O}_{L \times 1}, \boldsymbol{\Lambda})$ ,  $X_t \sim \mathcal{CN}(\mathbf{O}_{L \times 1}, \mathbf{A}(\theta)\boldsymbol{\Gamma}\mathbf{A}(\theta)^* + \boldsymbol{\Lambda})$ ,  $t = 1, \dots, T$ , где  $\mathcal{CN}$  соответствует комплексному нормальному распределению с нулевой псевдоковариацией. Шум и сигнал предполагаются независимыми между собой дискретными комплексными гауссовскими процессами с независимыми и одинаково распределенными отсчетами. Матрица  $\boldsymbol{\Lambda}$  предполагается диагональной. Требуется найти оптимальные оценки параметров  $\Upsilon = (\theta, \boldsymbol{\Gamma})$ .

### 3. ОПИСАНИЕ АЛГОРИТМА

Воспользуемся EM-алгоритмом для того, чтобы оценить значения параметров  $\Upsilon$ ,  $\Xi = (X_m, S)$  – латентные переменные (недоступные значения и сигналы). Пусть  $\Xi_t = (X_{t,m_t}, S_t)$  – набор латентных переменных, соответствующих наблюдению  $X_t$ , причем для отдельных наблюдений  $X_{t,m_t} = \emptyset$ . Алгоритм состоит из двух шагов:

- **E-шаг:** найти математическое ожидание полного правдоподобия с учетом апостериорного распределения латентных переменных:

$$\mathbb{M}_{q(\Xi)}[\log P(X, S)],$$

где

$$q(\Xi) = P(X_m, S | X_o = x_o, \Upsilon^{(\tau-1)}),$$

причем  $\tau$  – номер итерации EM-алгоритма.

- **M-шаг:**

$$\Upsilon^{(\tau)} = \arg \max_{\Upsilon \in \mathbb{R}^{K^2+K}} \mathbb{M}_{q(\Xi)}[\log P(X, S)].$$

#### 3.1. E-шаг

Из построения модели наблюдений следует независимость и одинаковая распределенность наблюдений  $X_t$ ,  $t = 1, \dots, T$ . Требуется найти математическое ожидание полного правдоподобия с учетом текущей оценки параметров и апостериорного совместного распределения пропущенных значений в наблюдениях  $X_m$  и сигналов  $S$

$$\mathbb{M}_{q(\Xi)}[\log P(X, S)] = \mathbb{M}_{(X_m, S) | X_o = x_o, \Upsilon^{(\tau-1)}}[\log P(X, S)].$$

Преобразуем выражение, учитывая тот факт, что наблюдения являются независимыми и одинаково распределенными, и обозначив через  $\mathcal{I}$  доступную информацию  $X_o = x_o, \Upsilon^{(\tau-1)}$  на

итерации  $\tau$  и через  $q(\Xi_t)$  распределение  $\mathsf{P}(X_{t,m_t}, S_t | X_{t,o_t} = x_{t,o_t}, \Upsilon^{(\tau-1)})$ :

$$\begin{aligned} \mathsf{M}_{q(\Xi)}[\log \mathsf{P}(X, S)] &= \\ \mathsf{M}_{q(\Xi)}[\log \mathsf{P}(X | S) + \log \mathsf{P}(S)] &= \\ \left[ \sum_{t=1}^T \mathsf{M}_{q(\Xi_t)} \log [\mathsf{P}(X_t | S_t)] + \sum_{t=1}^T \mathsf{M}_{q(\Xi_t)} [\log \mathsf{P}(S_t)] \right] &= \\ -T \left[ \log |\Lambda| + \text{Tr} (\Lambda^{-1} \mathsf{M}_{q(\Xi)}[XX^*]) - 2 \operatorname{Re} \text{Tr} (\mathbf{A}^*(\theta) \Lambda^{-1} \mathsf{M}_{q(\Xi)}[XS^*]) \right. & \\ \left. + \text{Tr} (\Lambda^{-1} \mathbf{A}(\theta) \mathsf{M}_{q(\Xi)}[SS^*] \mathbf{A}^*(\theta)) + \log |\Gamma| + \text{Tr} (\Gamma^{-1} \mathsf{M}_{q(\Xi)}[SS^*]) \right], & \end{aligned}$$

где:

$$\mathsf{M}_{q(\Xi)}[XX^*] = \frac{1}{T} \sum_{t=1}^T \mathsf{M}_{q(\Xi)}[X_t X_t^*], \quad (2)$$

$$\mathsf{M}_{q(\Xi)}[SS^*] = \frac{1}{T} \sum_{t=1}^T \mathsf{M}_{q(\Xi)}[S_t S_t^*], \quad (3)$$

$$\mathsf{M}_{q(\Xi)}[XS^*] = \frac{1}{T} \sum_{t=1}^T \mathsf{M}_{q(\Xi)}[X_t S_t^*]. \quad (4)$$

Распределение  $\mathsf{P}(X_{t,m_t}, S_t | X_{t,o_t})$  задается однозначно следующими условиями [16]:

1.  $S_t$  и  $N_t$  независимы  $\forall t \in \{1, \dots, T\}$ ;
2.  $\mathbf{A}(\theta)$  – матрица линейного преобразования;
3.  $S_t, N_t$  – комплексные гауссовские векторы, которые имеют нулевую псевдоковариацию.

На практике, не требуется напрямую находить ковариации для распределений  $q(\Xi_t), t = 1, \dots, T$ , достаточно лишь найти усредненные условные вторые моменты  $\mathsf{M}_{q(\Xi)}[XX^*]$ ,  $\mathsf{M}_{q(\Xi)}[XS^*]$ ,  $\mathsf{M}_{q(\Xi)}[SS^*]$ , используя формулы (2-4).

Рассмотрим случай, когда наблюдение  $X_t$  является полностью доступным, т.е.  $m_t = \emptyset$ . Тогда, апостериорное распределение  $\mathsf{P}(X_{t,m_t}, S_t | \mathcal{I}_t)$  сводится к распределению  $\mathsf{P}(S_t | \mathcal{I}_t)$ , а условные моменты  $\mathsf{M}[X_t X_t^* | \mathcal{I}_t]$ ,  $\mathsf{M}[X_t S_t^* | \mathcal{I}_t]$ ,  $\mathsf{M}[S_t S_t^* | \mathcal{I}_t]$  вычисляются по следующей схеме. Находим параметры апостериорного распределения  $\mathsf{P}(S_t | \mathcal{I}_t), t = 1, \dots, T$ :

$$\begin{cases} \mathsf{M}[S_t | \mathcal{I}_t] = \Gamma^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} x_t, \\ \text{cov}(S_t | \mathcal{I}_t) = \Gamma - \Gamma^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \mathbf{A} \Gamma. \end{cases}$$

И вычисляем условные моменты следующим образом:

$$\begin{aligned} \mathsf{M}[X_t X_t^* | \mathcal{I}_t] &= \mathsf{M}[X_t | \mathcal{I}_t] \cdot \mathsf{M}[X_t^* | \mathcal{I}_t] = x_t x_t^*, \\ \mathsf{M}[X_t S_t^* | \mathcal{I}_t] &= \mathsf{M}[X_t | \mathcal{I}_t] \cdot \mathsf{M}[S_t^* | \mathcal{I}_t] = x_t \cdot \mathsf{M}[S_t^* | \mathcal{I}_t] = x_t \cdot x_t^* \cdot \hat{\mathbf{R}}^{-1} \mathbf{A} \Gamma, \\ \mathsf{M}[S_t S_t^* | \mathcal{I}_t] &= \mathsf{M}[S_t | \mathcal{I}_t] \cdot \mathsf{M}[S_t^* | \mathcal{I}_t] + \text{cov}(S_t | \mathcal{I}_t). \end{aligned}$$

Теперь рассмотрим случай, когда наблюдение  $X_t$  содержит пропуски, т.е.  $m_t \neq \emptyset$ . Сначала найдем апостериорное распределение  $\mathsf{P}(X_m | \mathcal{I})$ . Для достижения этой цели, для каждой пары  $\{(o_t, m_t) : m_t \neq \emptyset\}$  создадим разбиение оценки ковариационной матрицы наблюдений  $\hat{\mathbf{R}}$  на блоки, индуцированное этим разбиением множества индексов, оно имеет следующий вид:

$$\hat{\mathbf{R}} = \begin{pmatrix} \hat{\mathbf{R}}_{o_t, o_t} & \hat{\mathbf{R}}_{o_t, m_t} \\ \hat{\mathbf{R}}_{m_t, o_t} & \hat{\mathbf{R}}_{m_t, m_t} \end{pmatrix},$$

где каждый блок определяется как

$$\hat{\mathbf{R}}_{a,b} = (\hat{\mathbf{R}}_{ij})_{i \in a, j \in b}.$$

Для каждого наблюдения, содержащего пропуски, требуется найти апостериорное распределение пропущенных значений,  $\mathsf{P}(X_{t,m_t} | X_{t,o_t} = x_{t,o_t}, \Upsilon^{(\tau-1)}), t = 1, \dots, T, m_t \neq \emptyset$ . Обозначим через  $\mathcal{I}_t$  доступную информацию  $X_{t,o_t} = x_{t,o_t}, \Upsilon^{(\tau-1)}$  на итерации  $\tau$ . Параметры апостериорного распределения  $\mathsf{P}(X_{t,m_t} | \mathcal{I}_t), t = 1, \dots, T$  на итерации  $\tau$  можно найти следующим образом [17]:

$$\begin{cases} \mathsf{M}[X_{t,m_t} | \mathcal{I}_t] = \hat{\mathbf{R}}_{m_t,o_t} (\hat{\mathbf{R}}_{o_t,o_t})^{-1} \cdot x_{t,o_t}, \\ \text{cov}(X_{t,m_t} | \mathcal{I}_t) = \hat{\mathbf{R}}_{m_t,m_t} - \hat{\mathbf{R}}_{m_t,o_t} (\hat{\mathbf{R}}_{o_t,o_t})^{-1} \hat{\mathbf{R}}_{o_t,m_t}, \end{cases}$$

где  $\hat{\mathbf{R}}_{o_t,o_t} = \hat{\mathbf{R}}_{o_t,o_t}^{(\tau-1)}$ ,  $\hat{\mathbf{R}}_{o_t,m_t} = \hat{\mathbf{R}}_{o_t,m_t}^{(\tau-1)}$ ,  $\hat{\mathbf{R}}_{m_t,o_t} = \hat{\mathbf{R}}_{m_t,o_t}^{(\tau-1)}$ ,  $\hat{\mathbf{R}}_{m_t,m_t} = \hat{\mathbf{R}}_{m_t,m_t}^{(\tau-1)}$ .

Для каждого наблюдения  $X_t$ , содержащего пропуски, определим условные первый и второй начальный момент  $\mathsf{M}[X_t X_t^* | \mathcal{I}_t]$ :

$$\begin{aligned} \mathsf{M}[X_t | \mathcal{I}_t] &= \mathsf{M}\left[\begin{pmatrix} X_{t,o_t} \\ X_{t,m_t} \end{pmatrix} | \mathcal{I}_t\right] = \begin{pmatrix} x_{t,o_t} \\ \mathsf{M}[X_{t,m_t} | \mathcal{I}_t] \end{pmatrix}, \\ \mathsf{M}[X_t X_t^* | \mathcal{I}_t] &= \mathsf{M}[X_t | \mathcal{I}_t] \cdot \mathsf{M}[X_t^* | \mathcal{I}_t] + \text{cov}(X_t | \mathcal{I}_t) \\ &= \mathsf{M}[X_t | \mathcal{I}_t] \cdot \mathsf{M}[X_t^* | \mathcal{I}_t] + \begin{pmatrix} \mathbf{O}_{o_t,o_t} & \mathbf{O}_{o_t,m_t} \\ \mathbf{O}_{m_t,o_t} & \text{cov}(X_{t,m_t} | \mathcal{I}_t) \end{pmatrix}, \end{aligned}$$

где  $\mathbf{O}_{o_t,o_t}$ ,  $\mathbf{O}_{o_t,m_t}$ ,  $\mathbf{O}_{m_t,o_t}$  – нулевые блочные матрицы. Разбиение указанной матрицы на четыре блока, три из которых состоят из нулей, индукцировано разбиением множества индексов  $\{1, \dots, L\}$  на множества  $o_t, m_t$ .

Параметры апостериорного распределения  $\mathsf{P}(S_t | \mathcal{I}_t), t = 1, \dots, T$  можно найти следующим образом:

$$\begin{cases} \mathsf{M}[S_t | \mathcal{I}_t] = \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \mathsf{M}[X_t | \mathcal{I}_t], \\ \text{cov}(S_t | \mathcal{I}_t) = \boldsymbol{\Gamma} - \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma} + \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \text{cov}(X_t | \mathcal{I}_t) \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma}, \end{cases}$$

где  $\mathbf{A} = \mathbf{A}(\theta^{(\tau-1)})$ ,  $\boldsymbol{\Gamma} = \boldsymbol{\Gamma}^{(\tau-1)}$ ,  $\hat{\mathbf{R}} = \hat{\mathbf{R}}^{(\tau-1)}$ ; эти же обозначения используются и далее, если не оговорено иное. Для вывода этих формул используются телескопическое свойство условного математического ожидания и закон полной дисперсии (подробности приведены в приложении Б).

Оценим  $\mathsf{M}[S_t S_t^* | \mathcal{I}_t]$ :

$$\mathsf{M}[S_t S_t^* | \mathcal{I}_t] = \mathsf{M}[S_t | \mathcal{I}_t] \cdot \mathsf{M}[S_t^* | \mathcal{I}_t] + \text{cov}(S_t | \mathcal{I}_t),$$

Оценим  $\mathsf{M}[X_t S_t^* | \mathcal{I}_t]$ :

$$\mathsf{M}[X_t S_t^* | \mathcal{I}_t] = \mathsf{M}[X_t X_t^* | \mathcal{I}_t] \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma}.$$

### 3.2. M-шаг

Требуется найти наилучшую оценку параметров, решив следующую задачу оптимизации:

$$\begin{aligned} \boldsymbol{\Upsilon}^{(\tau)} &= \arg \max_{\boldsymbol{\Upsilon} \in \mathbb{R}^{K^2+K}} \mathsf{M}_{q(\Xi)}[\log \mathsf{P}(X, S)] = \\ &\arg \min_{\boldsymbol{\Upsilon} \in \mathbb{R}^{K^2+K}} T \left[ \log |\boldsymbol{\Lambda}| + \text{Tr}(\boldsymbol{\Lambda}^{-1} \mathsf{M}_{q(\Xi)}[XX^*]) - 2 \operatorname{Re} \text{Tr}(\mathbf{A}^*(\theta) \boldsymbol{\Lambda}^{-1} \mathsf{M}_{q(\Xi)}[XS^*]) \right. \\ &\quad \left. + \text{Tr}(\boldsymbol{\Lambda}^{-1} \mathbf{A}(\theta) \mathsf{M}_{q(\Xi)}[SS^*] \mathbf{A}^*(\theta)) + \log |\boldsymbol{\Gamma}| + \text{Tr}(\boldsymbol{\Gamma}^{-1} \mathsf{M}_{q(\Xi)}[SS^*]) \right]. \end{aligned}$$

Оценим угловые координаты источников  $\theta$ :

$$\begin{aligned}\theta^{(\tau)} = \arg \min_{\theta \in \mathbb{R}^K} \mathcal{Q}_1(\theta | \theta^{(\tau-1)}) &= \arg \min_{\theta \in \mathbb{R}^K} \left[ -2 \operatorname{Re} \operatorname{Tr} (\mathbf{A}^*(\theta) \mathbf{\Lambda}^{-1} \mathbf{M}_{q(\Xi)} [XS^*]) \right. \\ &\quad \left. + \operatorname{Tr} (\mathbf{\Lambda}^{-1} \mathbf{A}(\theta) \mathbf{M}_{q(\Xi)} [SS^*] \mathbf{A}^*(\theta)) \right].\end{aligned}$$

Эту задачу можно решить численно, подробности приведены в приложении В.

Оценим ковариацию сигналов  $\mathbf{\Gamma}$ :

$$\mathbf{\Gamma}^{(\tau)} = \arg \min_{\mathbf{\Gamma} \in \mathbb{R}^{K^2}} \mathcal{Q}_2(\mathbf{\Gamma} | \mathbf{\Gamma}^{(\tau-1)}) = \arg \min_{\mathbf{\Gamma} \in \mathbb{R}^{K^2}} T \left[ \log |\mathbf{\Gamma}| + \operatorname{Tr} (\mathbf{\Gamma}^{-1} \mathbf{M}_{q(\Xi)} [SS^*]) \right] = \mathbf{M}_{q(\Xi)} [SS^*].$$

Обновляем оценку ковариации наблюдений с учетом полученных оценок параметров:

$$\hat{\mathbf{R}}^{(\tau)} = \mathbf{A}(\theta^{(\tau)}) \mathbf{\Gamma}^{(\tau)} \mathbf{A}^*(\theta^{(\tau)}) + \mathbf{\Lambda}.$$

#### 4. РЕЗУЛЬТАТЫ ЧИСЛЕННОГО ЭКСПЕРИМЕНТА

##### 4.1. Первый набор начальных условий

Рассматриваются следующие начальные условия:  $L = 25, K = 1, T = 12, 10$  сенсоров неисправны, на каждом из таких сенсоров 50% данных отсутствует,  $\theta = [0.7] \approx [40.107^\circ]$ . Мощность сигнала  $\rho_1$ , соответствующая первому источнику, равна -3dB. Мощность шума  $\rho_{noise}$  равна 9dB.

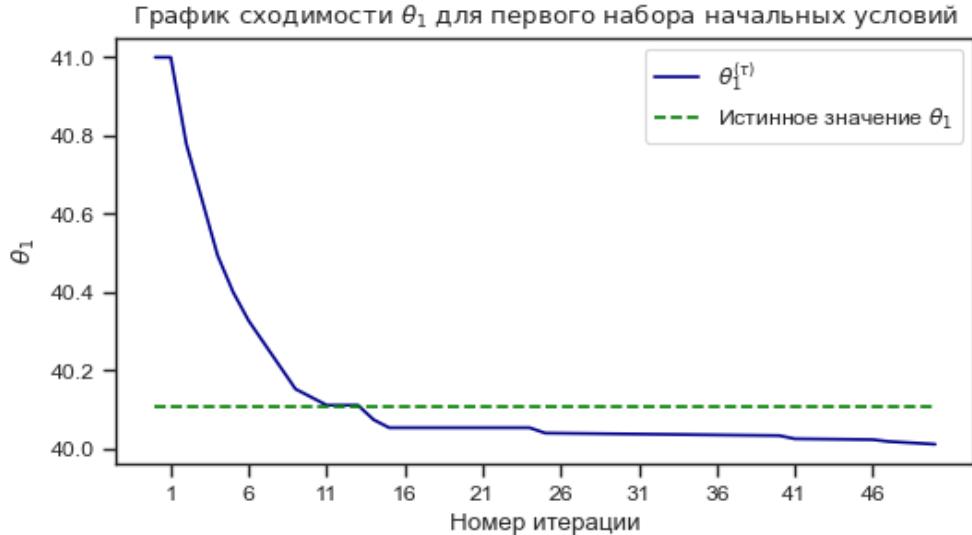


Рис. 1. График сходимости угловой координаты для первого набора начальных условий

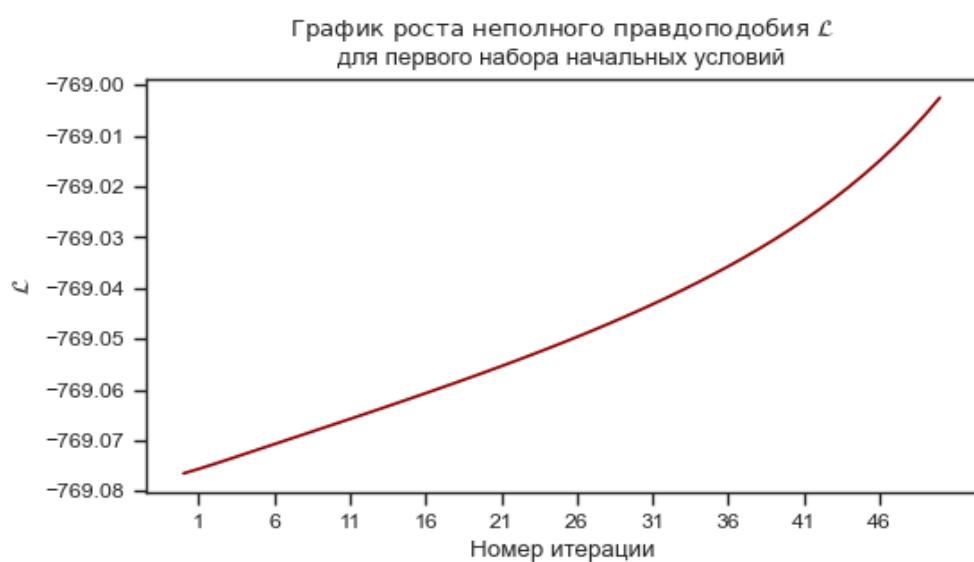


Рис. 2. График роста  $\log P(X_o | \Upsilon)$  для первого набора начальных условий

#### 4.2. Второй набор начальных условий

Рассматриваются следующие начальные условия:  $L = 40, K = 1, T = 20, 20$  сенсоров неисправны, на каждом из таких сенсоров 50% данных отсутствует,  $\theta = [-0.50.7] \approx [-28.65^{\circ} 40.107^{\circ}]$ . Мощность сигнала  $\rho_1$ , соответствующая первому источнику, равна 0,8 dB. Мощность сигнала  $\rho_2$ , соответствующая второму источнику, равна 1 dB. Мощность шума  $\rho_{noise}$  равна 4 dB.

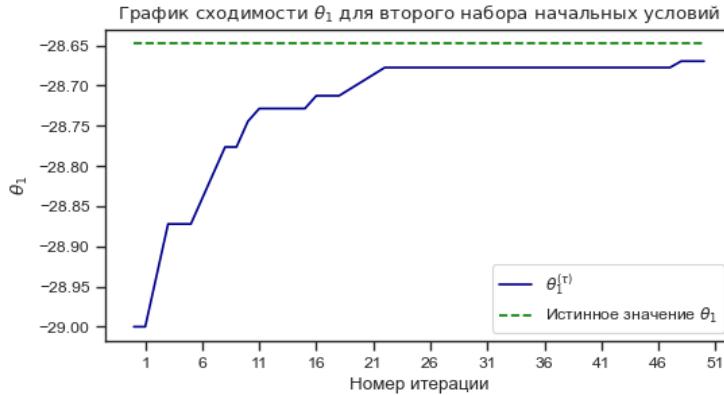


Рис. 3. График сходимости угловой координаты для второго набора начальных условий

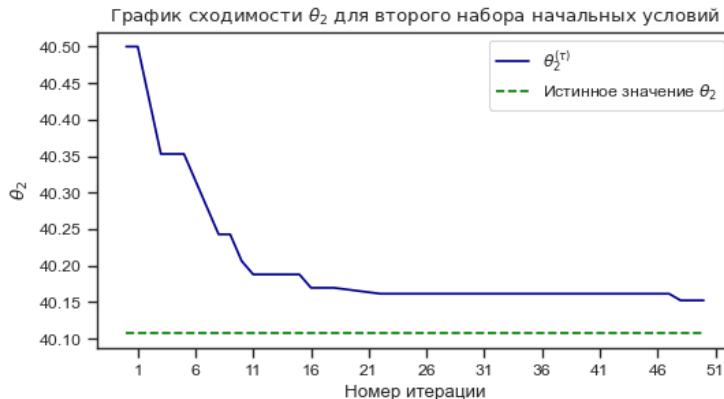


Рис. 4. График сходимости угловой координаты для второго набора начальных условий

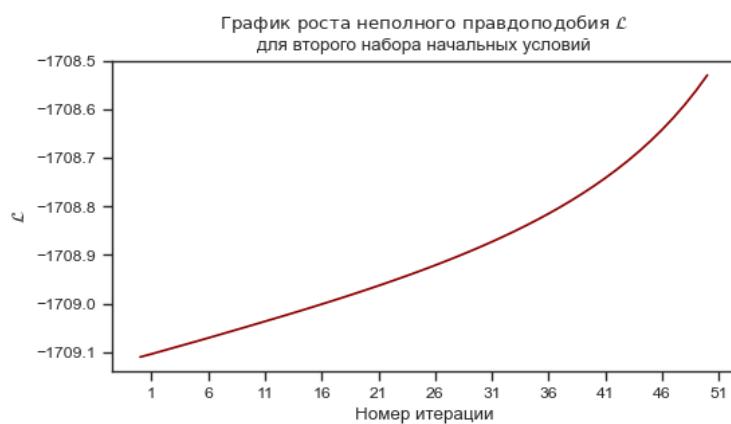


Рис. 5. График роста  $\log P(X_o | \Upsilon)$  для второго набора начальных условий

## 5. ЗАКЛЮЧЕНИЕ

## ПРИЛОЖЕНИЕ А. ИНИЦИАЛИЗАЦИЯ

Оценим ковариационную матрицу  $\hat{\mathbf{R}}^{(0)}$  следующим образом: если  $\sum_t \mathbf{I}_{x_t=x_{t,o_t}} \geq L$ , оцениваем  $\hat{\mathbf{R}}^{(0)}$  по выборке, образованной  $x_t : x_t = x_{t,o_t}$ . В противном случае используется следующий подход: пусть  $x^l$  – строка матрицы  $X$ , соответствующая сенсору  $l$ ,  $l = 1, \dots, L$ ,  $x_o^l$  – выборка, образованная доступными наблюдениями в строке  $l$ ,  $x_m^l$  – выборка, образованная недоступными наблюдениями в строке  $l$ ,  $x_t^l$  – компонента наблюдения  $x_t$ , соответствующая сенсору  $l$ . Для всех недоступных значений построим следующую оценку: если  $x_t^l \in x_m^l$ ,  $l = 1, \dots, L$ ,  $t = 1, \dots, T$ , то  $\hat{x}_t^l = \overline{x_o^l}$ . Оцениваем ковариацию по такому оцененному набору  $\hat{x}$ :

$$\hat{\mathbf{R}}^{(0)} = \text{cov}(\hat{x}).$$

Оценим вектор угловых координат источников  $\theta^{(0)}$  следующим образом:

1. Выберем число  $\nu$ , которое будет соответствовать первому компоненту вектора  $\theta^{(0)}$ :

$$\nu \sim \mathcal{U}(-\pi; \pi);$$

2. Оценим компоненты вектора  $\theta^{(0)}$  так:  $\theta_i^{(0)} = (\nu + (i-1) \cdot \frac{2\pi}{K}) \bmod 2\pi$ ,  $i = 1, \dots, K$ . При этом,  $a \bmod b = a - b \cdot \lfloor \frac{a}{b} \rfloor$ .

Альтернативный подход: используем  $\hat{\mathbf{R}}^{(0)}$  для оценки  $\theta^{(0)}$  с помощью алгоритма MUSIC, используем эту оценку на первой итерации мультистарта EM, на следующих используем оценки в окрестности указанной.

Начальную ковариацию сигналов  $\Gamma^{(0)}$  получаем на основе метода наименьших квадратов с помощью  $\theta^{(0)}$ ,  $\hat{\mathbf{R}}^{(0)}$ . Матрица  $\mathbf{A}(\theta^{(0)})$  – матрица векторов направленности и представима в следующем виде:

$$\mathbf{A}(\theta^{(0)}) = [\mathbf{A}(\theta_1^{(0)}), \dots, \mathbf{A}(\theta_K^{(0)})],$$

где  $\mathbf{A}(\theta_k^{(0)})$  – вектор направленности для источника  $k$ . Перед применением МНК каждый такой вектор отнормируем:

$$\check{\mathbf{A}}(\theta_k^{(0)}) = \frac{\mathbf{A}(\theta_k^{(0)})}{\|\mathbf{A}(\theta_k^{(0)})\|}, k = 1, \dots, K,$$

сформируем из них нормированную матрицу векторов направленности:

$$\check{\mathbf{A}}(\theta^{(0)}) = [\check{\mathbf{A}}(\theta_1^{(0)}), \dots, \check{\mathbf{A}}(\theta_K^{(0)})],$$

применяем МНК для получения нормированной ковариации мощностей:

$$\check{\Gamma}^{(0)} = \mathcal{D}[\check{\mathbf{A}}(\theta^{(0)})^+ (\hat{\mathbf{R}}^{(0)} - \Lambda)(\check{\mathbf{A}}(\theta^{(0)})^+)^*],$$

где  $\mathcal{D}[\cdot]$  – диагональное приближение матрицы,  $(\cdot)^+$  – псевдообратная матрица. Такой подход не гарантирует, что все элементы матрицы на главной диагонали будут неотрицательными, поэтому используем следующую корректировку:  $\check{\Gamma}_{ll}^{(0)} = \max(\check{\Gamma}_{ll}^{(0)}, \varepsilon)$ ,  $l = 1, \dots, L$ . Переходим к ненормированной мощности:

$$\Gamma_{ll}^{(0)} = \frac{\check{\Gamma}_{ll}^{(0)}}{\|a(\theta_k^{(0)})\|_l}, l = 1, \dots, L.$$

Требуется гарантировать, что при выбранной инициализации на Е-шаге не будет получена условная ковариация сигналов, не являющаяся положительной определенной. Вычисляем оценку условной ковариации сигналов, используя начальную оценку, и проверяем, выполняется ли свойство неотрицательной определенности:

$$\boldsymbol{\Gamma}^{(0)} - (\boldsymbol{\Gamma}^{(0)})^* \mathbf{A}(\theta^{(0)})^* (\hat{\mathbf{R}}^{(0)})^{-1} \mathbf{A}(\theta^{(0)}) \boldsymbol{\Gamma}^{(0)} \succeq 0,$$

пока это свойство не выполняется, домножаем матрицу на 0.5:  $\boldsymbol{\Gamma}^{(0)} = 0.5 \cdot \boldsymbol{\Gamma}^{(0)}$  и повторно проверяем выполнимость вышеуказанного свойства.

## ПРИЛОЖЕНИЕ Б. О КОРРЕКТНОСТИ Е-ШАГА

В рамках Е-шага необходимо вычислить  $\mathbf{M}[S_t | X_{t,o_t} = x_{t,o_t}]$ ,  $\text{cov}(S_t | X_{t,o_t} = x_{t,o_t})$ . Вычисление  $\mathbf{M}[S_t | X_{t,o_t} = x_{t,o_t}]$  реализуется так:

$$\begin{aligned}\mathbf{M}[S_t | X_{t,o_t} = x_{t,o_t}] &= \mathbf{M}[\mathbf{M}[S_t | X_t] | X_{t,o_t} = x_{t,o_t}] \\ &= \mathbf{M}[\boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} X_t | X_{t,o_t} = x_{t,o_t}] = \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \mathbf{M}[X_t | X_{t,o_t} = x_{t,o_t}].\end{aligned}$$

Для нахождения  $\text{cov}(S_t | X_{t,o_t} = x_{t,o_t})$  может быть использовано равенство, называемое законом полной дисперсии (Law of total variance, [18]):

$$\text{cov}(W) = \mathbf{M}[\text{cov}(W | Y)] + \text{cov}(\mathbf{M}[W | Y]).$$

Пусть  $\mathcal{F}_Z = \sigma(Z)$  – сигма-алгебра, порожденная  $Z$ . Тогда все числовые характеристики  $W$ , включая условные моменты и ковариации относительно  $Y$ , можно обусловить на  $\mathcal{F}_Z$ . И, соответственно, из закона полной ковариации следует:

$$\text{cov}(W | \mathcal{F}_Z) = \mathbf{M}[\text{cov}(W | Y, Z) | \mathcal{F}_Z] + \text{cov}(\mathbf{M}[W | Y, Z] | \mathcal{F}_Z).$$

Вектора  $W, Y, Z$  предполагаются комплексными гауссовскими (случай круговой симметрии), зависимость между  $Z$  и  $Y$  линейная,  $\sigma(Z) \subseteq \sigma(Y)$ , предполагается, что  $Z = CY$ , где  $C$  – булев селектор. Для линейной гауссовой модели знание  $Z$  не уменьшает условную ковариацию  $W | Y$  и не влияет на условное математическое ожидание  $\mathbf{M}[W | Y, Z]$ , поскольку  $Z$  не содержит никакой новой информации, которой не было бы в  $Y$ :

$$\begin{aligned}\text{cov}(W | Y, Z) &= \text{cov}(W | Y), \\ \mathbf{M}[W | Y, Z] &= \mathbf{M}[W | Y].\end{aligned}$$

Получаем:

$$\text{cov}(W | \mathcal{F}_Z) = \mathbf{M}[\text{cov}(W | Y) | \mathcal{F}_Z] + \text{cov}(\mathbf{M}[W | Y] | \mathcal{F}_Z).$$

Если  $Z = z$ , имеем:

$$\text{cov}(W | Z = z) = \mathbf{M}[\text{cov}(W | Y) | Z = z] + \text{cov}(\mathbf{M}[W | Y] | Z = z).$$

В рамках исходной задачи по оцениванию DoA и ковариации сигналов,  $W$  соответствует величине  $S_t$ ,  $Y$  соответствует величине  $X_t$ ,  $Z$  соответствует величине  $X_{t,o_t}$ ,  $z$  соответствует величине  $x_{t,o_t}, t = 1, \dots, T$ .

Получаем:

$$\text{cov}(S_t | X_{t,o_t} = x_{t,o_t}) = \mathbf{M}[\text{cov}(S_t | X_t) | X_{t,o_t} = x_{t,o_t}] + \text{cov}(\mathbf{M}[S_t | X_t] | X_{t,o_t} = x_{t,o_t}).$$

Преобразуем первое слагаемое, учитывая тот факт, что ковариация не зависит от реализации  $X_{t,o_t}$ .

$$\mathbf{M}[\text{cov}(S_t | X_t) | X_{t,o_t} = x_{t,o_t}] = \text{cov}(S_t | X_t) = \boldsymbol{\Gamma} - \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma}.$$

Теперь преобразуем второе слагаемое:

$$\begin{aligned}\text{cov}(\mathbf{M}[S_t | X_t] | X_{t,o_t} = x_{t,o_t}) &= \text{cov}(\boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} X_t | X_{t,o_t} = x_{t,o_t}) \\ &= \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \text{cov}(X_t | X_{t,o_t} = x_{t,o_t}) \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma}.\end{aligned}$$

Таким образом:

$$\text{cov}(S_t | X_{t,o_t} = x_{t,o_t}) = \boldsymbol{\Gamma} - \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma} + \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \text{cov}(X_t | X_{t,o_t} = x_{t,o_t}) \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma}.$$

Для полных наблюдений  $X_{t,o_t} = X_t$ , и, соответственно:

$$\text{cov}(\mathbb{M}[S_t | X_t] | X_{t,o_t} = x_{t,o_t}) = \text{cov}(\mathbb{M}[S_t | X_t] | X_t = x_t) = 0.$$

О выводе смешанных вторых моментов  $\mathbb{M}[X_t S_t^* | X_t = x_t]$  и  $\mathbb{M}[X_t S_t^* | X_{t,o_t} = x_{t,o_t}]$ :

$$\mathbb{M}[X_t S_t^* | X_t] = X_t \mathbb{M}[S_t^* | X_t] = X_t (\boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} X_t)^* = X_t X_t^* \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma},$$

$$\begin{aligned} \mathbb{M}[X_t S_t^* | X_{t,o_t} = x_{t,o_t}] &= \mathbb{M}[X_t \mathbb{M}[S_t^* | X_t] | X_{t,o_t} = x_{t,o_t}] = \mathbb{M}[X_t (\boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} X_t)^* | X_{t,o_t} = x_{t,o_t}] \\ &= \mathbb{M}[X_t X_t^* \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma} | X_{t,o_t} = x_{t,o_t}] = \mathbb{M}[X_t X_t^* | X_{t,o_t} = x_{t,o_t}] \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma} \end{aligned}$$

В приведенных выше переходах используется закон полного условного математического ожидания и уже полученное выражение для  $\mathbb{M}[S_t^* | X_t]$ .

## ПРИЛОЖЕНИЕ В. О РЕАЛИЗАЦИИ М-ШАГА

Если антенная решетка является равномерной и линейной, удобно искать оптимальный  $u = \sin(\theta)$ , а затем находить  $\theta$  как  $\arcsin(u)$ . Соответственно минимизации подлежит функция

$$\mathcal{Q}_1(u | u^{(\tau-1)}) = -2 \operatorname{Re} \operatorname{Tr} (\tilde{\mathbf{A}}^*(u) \mathbf{\Lambda}^{-1} \mathbf{M}_{q(\Xi)} [XS^*]) + \operatorname{Tr} (\mathbf{\Lambda}^{-1} \tilde{\mathbf{A}}(u) \mathbf{M}_{q(\Xi)} [SS^*] \tilde{\mathbf{A}}^*(u)),$$

где

$$\tilde{\mathbf{A}}(u) = \begin{bmatrix} 1 & 1 & \dots & 1 \\ e^{-2j\pi \frac{d}{\lambda} u_1} & e^{-2j\pi \frac{d}{\lambda} u_2} & \dots & e^{-2j\pi \frac{d}{\lambda} u_K} \\ \dots & \dots & \ddots & \vdots \\ e^{-2j\pi(L-1) \frac{d}{\lambda} u_1} & e^{-2j\pi(L-1) \frac{d}{\lambda} u_2} & \dots & e^{-2j\pi(L-1) \frac{d}{\lambda} u_K} \end{bmatrix}.$$

Для ускорения оптимизации можно оптимизировать не  $\mathcal{Q}_1(u | u^{(\tau-1)})$ , а суррогатную функцию  $\mathcal{G}(u | u^{(\tau-1)})$ , построенную так:

$$\mathcal{G}(u | u^{(\tau-1)}) = \mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)}) + \nabla \mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)})^T (u - u^{(\tau-1)}) + \frac{1}{2} (u - u^{(\tau-1)})^T \mathbf{H} (u - u^{(\tau-1)}),$$

где

$$\mathbf{H} = \begin{bmatrix} \max(|\nabla_1 \mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)})|, \varepsilon) & 0 & \dots & 0 \\ 0 & \max(|\nabla_2 \mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)})|, \varepsilon) & \dots & 0 \\ \dots & \dots & \ddots & \vdots \\ 0 & 0 & \dots & \max(|\nabla_K \mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)})|, \varepsilon) \end{bmatrix},$$

причем  $\nabla_i \mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)})$  –  $i$ -я компонента градиента  $\mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)})$ . Диагональная аппроксимация  $\mathbf{H}$  предотвращает слишком маленькие или слишком большие шаги, сохраняя численную стабильность. Теперь эту суррогатную функцию надо минимизировать (или, эквивалентно, найти направление шага  $\rho^{(\tau)} = u - u^{(\tau-1)}$ ):

$$\min_{u \in \mathbb{R}^K} \mathcal{G}(u | u^{(\tau-1)}).$$

Подставим  $u = u^{(\tau-1)} + \rho$ :

$$\mathcal{G}(u^{(\tau-1)} + \rho | u^{(\tau-1)}) = \mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)}) + \nabla \mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)})^T \rho + \frac{1}{2} \rho^T \mathbf{H} \rho.$$

Для нахождения минимума берем градиент по  $\rho$ :

$$\nabla_\rho \mathcal{G}(u^{(\tau-1)} + \rho | u^{(\tau-1)}) = \nabla \mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)}) + \mathbf{H} \rho,$$

при  $\nabla_\rho \mathcal{G} = 0$  будет выполняться:

$$0 = \nabla \mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)}) + \mathbf{H} \rho,$$

решаем относительно  $\rho^{(\tau)}$ :

$$\rho^{(\tau)} = -\mathbf{H}^{-1} \nabla \mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)}).$$

Важно заметить, что производная по направлению  $\nabla \mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)})^T \rho^{(\tau)}$  принимает вид:

$$\nabla \mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)})^T \rho^{(\tau)} = -\nabla \mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)})^T \mathbf{H}^{-1} \nabla \mathcal{Q}_1(u^{(\tau-1)} | u^{(\tau-1)}),$$

и поскольку  $\mathbf{H}$  – положительно определенная матрица, производная по направлению может принимать лишь неположительные значения, а значит направление  $\rho^{(\tau)}$  соответствует невозрастанию функции [19]. Далее используется backtracking line search в сочетании с проекцией на допустимое множество:

$$\tilde{u}^{(\tau)} = u^{(\tau-1)} + \alpha_m \rho^{(\tau)}, \quad u^{(\tau)} = \Pi_{\mathcal{U}}(\tilde{u}^{(\tau)}),$$

где  $\Pi_{\mathcal{U}}$  – евклидова проекция на множество

$$\mathcal{U} = [-1, 1]^L = \{u \in \mathbb{R}^L \mid \|u\|_\infty \leq 1\},$$

задаваемая покомпонентным ограничением:

$$(\Pi_{\mathcal{U}}(x))_i = \min\{1, \max\{-1, x_i\}\}.$$

Параметр шага  $\alpha_m$  выбирается как первое  $\alpha = \alpha_0 \beta^m$ ,  $m \in \mathbb{N}$ , такое что

$$\mathcal{Q}_1(u^{(\tau)} \mid u^{(\tau-1)}) \leq \mathcal{Q}_1(u^{(\tau-1)} \mid u^{(\tau-1)}),$$

при фиксированных  $\alpha_0 > 0$  и  $\beta \in (0, 1)$ .

В рамках программного комплекса реализуется мультистарт для поиска оптимального  $u$  на М-шаге. Указанный выше оптимизационный алгоритм запускается не только из точки  $u^{(\tau-1)}$ , но и из случайно выбранных допустимых точек, в том числе находящихся в окрестности  $u^{(\tau-1)}$ . Для выбранной начальной точки с индексом  $j$ , обновление оценки синусов угловых координат  $\tilde{u}^{(j)}$  может быть принято, только если:

1.  $\mathcal{Q}_1(\tilde{u}^{(j)} \mid u^{(\tau-1)}) > \mathcal{Q}_1(u^{(\tau-1)} \mid u^{(\tau-1)}),$
2.  $\mathcal{Q}_1(\tilde{u}^{(j)} \mid u^{(\tau-1)}) > \mathcal{Q}_1(\min(\tilde{u}^{(i)} : 1 \leq i \leq j-1) \mid u^{(\tau-1)}),$  при  $j > 1.$

Выбранный подход корректен ввиду следующих соображений:

1. Функция  $\mathcal{Q}_1(u \mid u^{(\tau-1)})$  дифференцируема, поскольку  $\tilde{\mathbf{A}}(u)$  состоит из экспонент вида  $e^{j\pi m u_k}$ ,  $k = 1, \dots, K$ ,  $m \in \mathbb{R}$ , т.е. гладких функций, умножение подобных матриц на фиксированные матрицы, взятие следа, взятие действительной части не нарушают гладкость.
2. Функция  $\mathcal{Q}_1(u \mid u^{(\tau-1)})$  ограничена снизу, поскольку вектор  $u$  принадлежит компакту  $\mathcal{U}$ , матрицы, определяющие вид функции  $\mathcal{Q}_1(u \mid u^{(\tau-1)})$  и отличные от  $\mathbf{A}(u)$ , являются фиксированными, след от произведения таких матриц, принимает лишь конечные значения.
3. Градиент  $\nabla \mathcal{Q}_1(u \mid u^{(\tau-1)})$  не принимает нулевые значения для любых  $u \in \mathcal{U}$ , поскольку  $\mathcal{Q}_1(u \mid u^{(\tau-1)})$  – гладкая функция, не сводящаяся к константе.

Оценим ковариацию сигналов  $\Gamma$ :

$$\Gamma^{(\tau)} = \arg \min_{\Gamma} \mathcal{Q}_2(\Gamma \mid \Gamma^{(\tau-1)}) = \arg \min_{\Gamma} T \left[ \log |\Gamma| + \text{Tr}(\Gamma^{-1} \mathbf{M}_{q(\Xi)}[SS^*]) \right].$$

Определим точку, где производная данной функции принимает значение 0, и, таким образом, находим минимум функции:

$$\begin{aligned} \frac{\partial}{\partial \Gamma} \log(\text{Det}(\Gamma)) &= \Gamma^{-1}, \\ \frac{\partial}{\partial \Gamma} \text{Tr}(\Gamma^{-1} \mathbf{M}_{q(\Xi)}[SS^*]) &= -\Gamma^{-1} \mathbf{M}_{q(\Xi)}[SS^*] \Gamma^{-1}, \\ \frac{\partial \mathcal{Q}_2(\Gamma)}{\partial \Gamma} &= \Gamma^{-1} - \Gamma^{-1} \mathbf{M}_{q(\Xi)}[SS^*] \Gamma^{-1}. \end{aligned}$$

Приравняем производную к нулю (функция по  $\Gamma$  выпукла):

$$\mathbf{O} = \Gamma^{-1} - \Gamma^{-1} \mathbf{M}_{q(\Xi)}[SS^*] \Gamma^{-1} \Rightarrow \Gamma^{(\tau)} = \mathbf{M}_{q(\Xi)}[SS^*].$$

Ввиду того, что М-шаг не максимизирует, а лишь улучшает УМО полного правдоподобия, представленный алгоритм является не точным ЕМ, а обобщенным (Generalized) ЕМ.

## СПИСОК ЛИТЕРАТУРЫ

1. Krim H., Viberg M. Two decades of array signal processing research: the parametric approach. *IEEE Signal Processing Magazine*, 1996, Vol. 13, No. 4, pp. 67–94.
2. Godara L. C. Application of antenna arrays to mobile communications. Part II: Beam-forming and direction-of-arrival considerations. *Proceedings of the IEEE*, 1997, Vol. 85, No. 8, pp. 1195-1245.
3. Dempster A. P., Laird N. M., Rubin D. B. Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society: Series B (Methodological)*, 1977, Vol. 39, No. 1, pp. 1-38.
4. Meng X.-L., Rubin D. B. Maximum likelihood estimation via the ECM algorithm: a general framework. *Biometrika*, 1993, Vol. 80, No. 2, pp. 267-278.
5. Fessler J. A., Hero A. O. Space-alternating generalized expectation-maximization algorithm. *IEEE Transactions on Signal Processing*, 1994, Vol. 42, No. 10, pp. 2664-2677.
6. Miller M. I., Fuhrmann D. R. Maximum-likelihood narrow-band direction finding and the EM algorithm. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 1990, Vol. 38, No. 9, pp. 1560-1577.
7. Feder M., Weinstein E. Parameter estimation of superimposed signals using the EM algorithm. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 1988, Vol. 36, No. 4, pp. 477-489.
8. Gong M.-Y., Lyu B. Alternating maximization and the EM algorithm in maximum-likelihood direction finding. *IEEE Trans. Veh. Technol.*, 2021, Vol. 70, No. 10, pp. 9634-9645.
9. Gong M.-Y., Lyu B. EM and SAGE Algorithms for DOA Estimation in the Presence of Unknown Uniform Noise. *Sensors*, 2023, Vol. 23, No. 10.
10. Gong, M.-Y.; Lyu, B. Stochastic Maximum Likelihood Direction Finding in the Presence of Nonuniform Noise Fields. *Electronics*, 2023, Vol. 12, No. 10.
11. Schwartz O., Dorfan Y., Taseska M., Habets E. A. P., Gannot S. DOA estimation in noisy environment with unknown noise power using the EM algorithm. *2017 Hands-free Speech Communications and Microphone Arrays (HSCMA)*, San Francisco, CA, USA, 2017, pp. 86-90.
12. Xunxue C., Kegen Y., Songsheng L. Direction Finding for Transient Acoustic Source Based on Biased TDOA Measurement. *IEEE Transactions on Instrumentation and Measurement*, 2016, Vol. 65, No. 11, pp.2442-2453.
13. Wen F., Liu W., Lu X. Distributed Expectation-Maximization Algorithm for DOA Estimation in Wireless Sensor Networks. *2015 IEEE International Conference on Digital Signal Processing (DSP)*, Singapore, 2015, pp. 944-947.
14. Gimenez-Febrer P., Pages-Zamora A., Lopez-Valcarce R. Online EM-based distributed estimation in sensor networks with faulty nodes. *2016 24th European Signal Processing Conference (EUSIPCO)*, Budapest, Hungary, 2016, pp. 175-179.
15. Rubin, D.B. Inference and missing data. *Biometrika*, Vol. 63, No. 3, pp. 581-592.
16. Schreier P. J., Scharf L. L. *Statistical Signal Processing of Complex-Valued Data: The Theory of Improper and Noncircular Signals*. Cambridge: Cambridge University Press, 2010. 309p., pp. 41-42.
17. Little R. J. A., Rubin D. B. *Statistical analysis with missing data 3rd ed.* Hoboken, N. J.: Wiley, 2019, 462p.
18. Ross S. M. *A first course in probability. 8th ed.* Upper Saddle River, N. J.: Prentice Hall, 2010. 640p., p. 348.
19. Nocedal J., Wright S.J. *Numerical Optimization. 2nd ed.* New York: Springer, 2006. 664p., pp. 10-37.